

Karpathy 视频 Session 切分指南 + 课前问题(Chapter 1-7)

用法:每个会话开始前,先读该段的 3-4 个课前问题(1 分钟),带着问题跟敲;收工时口头回答一遍作为自测。

切分点对齐 YouTube 官方章节(进度条分段),按章节标题定位,此处只给内容边界不给精确时间戳。

记号:■ = 收工状态(必须达到才停)。会话时长为**含跟敲的实际耗时**估计。

Chapter 1 micrograd(视频约 2.5h → 3 个会话)

会话 1:导数直觉 → Value 类与手动反向(≈90min)

范围:开头至"手动做完一个小表达式的 backprop"(章节:intro / derivative / Value object 附近)。

课前问题:

1. 只用 $(f(x+h)-f(x))/h$ 这一个工具,如何得到一个多输入表达式对每个输入的敏感度?
2. 链式法则在"计算图"上对应什么操作?局部梯度指什么?
3. 为什么每个 Value 节点要同时存 data 和 grad 两个字段?
■ 手动(不用 backward())算对一个小表达式所有节点的梯度。

会话 2:backward() 自动化 → tanh 与梯度累积(≈90min)

范围:拓扑排序实现 backward,至 tanh 神经元与"bug: 梯度累积"段落。

课前问题:

1. 为什么反向传播必须按拓扑序?乱序会错在哪?
2. 一个节点被使用两次(如 $b = a + a$),梯度应该怎么处理? $+=$ 和 $=$ 的差别会造成什么 bug?
3. tanh 可以作为一个原子操作实现,也可以拆成 exp/加减乘除的复合——两种实现的梯度会一致吗?为什么?
■ backward() 跑通,与会话 1 的手算结果一致。

会话 3:MLP + 训练循环 + 对照 PyTorch(≈90min)

范围:Neuron/Layer/MLP 类,loss,训练循环,至与 PyTorch 对照收尾。

课前问题:

1. 一次完整的训练迭代由哪四步构成?哪一步最容易被忘掉、忘掉后症状是什么?(提示:zero_grad)
2. 学习率过大/过小分别在 loss 曲线上长什么样?

3. micrograd 的 Value 和 PyTorch 的 tensor,最本质的对应关系是什么?

- 二层 MLP 在小数据集上 loss 稳定下降;PyTorch 对照段跑通。

Chapter 2Imakemore #1 bigram(视频约 2h → 2 个会话)

会话 1:计数模型 + 采样 + NLL($\approx 100\text{min}$)

范围:开头至 negative log likelihood 评估。

课前问题:

1. "语言模型"最小可以简化到什么程度?bigram 丢掉了什么信息?
2. 从一个概率表里采样下一个字符,具体怎么操作?
3. 为什么用负对数似然而不是直接用似然?平均 NLL 等于多少时模型等于瞎猜?
 - 计数版 bigram 能生成名字(哪怕很难听),NLL 计算跑通。

会话 2:神经网络版 bigram + 等价性($\approx 100\text{min}$)

范围:one-hot、单层网络、softmax、梯度下降,至正则化与平滑的等价性收尾。

课前问题:

1. one-hot 向量乘一个矩阵,等价于什么操作?
2. 为什么 softmax 前的量叫 logits?exp 在这里起什么作用?
3. 计数模型里的"平滑(加常数)"在神经网络版里对应什么?(提示:对 W 的什么约束?)
 - NN 版训练后 loss 收敛到与计数版几乎相同——并能说出为什么"几乎相同"是必然的。

Chapter 2Imakemore #2 MLP(视频约 1.3h → 2 个会话)

会话 1:上下文窗口 + embedding + 隐层($\approx 75\text{min}$)

课前问题:

1. bigram 的根本瓶颈是什么?扩大上下文后,计数方法为什么立刻不可行?
2. embedding 查表和 one-hot 矩阵乘是什么关系?
3. 三个字符的 embedding 拼接成一个向量,张量形状怎么变?(预演 view 操作)
 - 前向传播跑通,loss 能算出来。

会话 2:minibatch + 学习率搜索 + 数据划分($\approx 75\text{min}$)

课前问题:

1. 为什么用 minibatch 而不是全量数据?梯度会变"错"吗,错了为什么还能用?
2. 怎么系统地找一个合理的学习率区间,而不是瞎试?

3. train/dev/test 三份各自回答什么问题?只有 train/test 两份会出什么事?
- 完整训练跑通,dev loss 低于 bigram 基线。〔工程〕本次训练在 AutoDL 远程完成——正好当Chapter 2 远程首航的载荷。
-

Chapter 3Imakemore #3 激活/梯度/BatchNorm(视频约 2h → 3 个会话)

会话 1:初始化问题(≈60min)

课前问题:

1. 训练第 0 步的 loss 应该约等于多少?(能不能在跑之前算出来?)如果实际远高于它,说明什么?
2. tanh 输出全在 ± 1 附近意味着什么?为什么这会"杀死"梯度?
3. 把权重初始化简单乘个小系数,为什么有效?系数怎么定才不是拍脑袋?(引出 Kaiming)
 - 复现"初始 loss 过高→修复"的全过程,画出 tanh 激活直方图修复前后的对比。

会话 2:BatchNorm(≈75min)

课前问题:

1. BatchNorm 想让隐层的"预激活"满足什么统计性质?为什么标准化之后还要 gain 和 bias?
2. BatchNorm 让每个样本的输出依赖同 batch 的其他样本——这是 bug 还是 feature?
3. 推理时没有 batch,均值方差从哪来?
 - 手写 BatchNorm 层并训练通过;能说出它放在线性层之后为什么 bias 变得多余。

会话 3:诊断仪表盘(≈75min)

课前问题:

1. 健康的训练里,各层激活分布、梯度分布应该长什么样?逐层递减/递增说明什么?
 2. update/param 比值多大算健康?这个数和学习率是什么关系?
 3. 如果只允许看三张图判断训练是否健康,你选哪三张?
 - 复现视频里的四类统计图,并存储为你以后所有项目可复用的诊断代码片段(这是本视频的真正遗产)。
-

Chapter 4|makemore #4 backprop ninja(视频约 2h → 3 个会话)

本集形态特殊:一个大 exercise,逐张量手写梯度再与 autograd 对答案。切分按 exercise 的自然分段。

会话 1:损失端反向(cross-entropy 链条)(≈90min)

课前问题:

1. 从 loss 反推:logprobs、probs、counts、logits,每一步梯度的形状必须和什么一致?
2. 为什么 softmax + cross-entropy 合并后梯度会简化成 $(p - y)$ 这么干净的形式?
3. 广播(broadcast)过的张量,反向时梯度要做什么补偿操作?(这是 MATLAB 转 Python 最易错点)
 - 反向传播通过 cross-entropy 链条,cmp 校验全部 exact。

会话 2:线性层 + tanh + embedding 反向(≈90min)

课前问题:

1. $d\text{loss}/dW$ 的公式里,为什么出现的是输入的转置?用形状对齐法怎么快速推出来?
2. 同一个 embedding 行被多个位置索引到,梯度怎么汇聚?
3. batch 维度上梯度为什么是"求和"而不是"平均"?什么时候会变成平均?
 - 全部张量 cmp 通过。

会话 3:BatchNorm 反向 + 整合(≈90min)

课前问题:

1. BatchNorm 的反向为什么比前向难得多?难点具体在均值和方差对每个输入的依赖上,怎么处理?
2. 手推出的 BatchNorm 梯度公式,哪些项对应"去均值",哪些对应"去相关"?
3. 做完这一切,你获得的能力用一句话概括是什么?(自己写答案,收工时修订)
 - 全视频 exercises 完成;★ 隔日闭卷:手推 softmax+CE 合并梯度。

Chapter 5|makemore #5 WaveNet(视频约 1h → 1-2 个会话)

会话 1(可一次完成,≈100min;拆两次则在"容器化改写"处断开)

课前问题:

1. 把上下文从 3 字符扩到 8 字符,朴素 MLP 的参数量和信息瓶颈各出什么问题?
2. 层级式两两合并(WaveNet 结构)为什么更合理?感受野随层数怎么增长?

3. 这个结构和你熟悉的多级滤波器组/金字塔分解,对应点和差异点各是什么?(信号处理主场题)
 4. torch 的 view/squeeze 在 (B, T, C) 张量重组时怎么配合?
 - 层级模型训练通过,loss 优于 #2 的平坦 MLP;半页"卷积 vs 滤波器组"笔记完成。
-

Chapter 6–7|Let's build GPT(视频约 2h → 4 个会话)

会话 1:bigram 基线 + 数据管线($\approx 60\text{min}$)

课前问题:

1. 字符级 tokenizer 的编解码最少需要哪两个映射?
2. get_batch 里 x 和 y 错开一位,一个 (B,T) 的 batch 实际含多少个训练样本?
3. 这里的 bigram 和 makemore #1 的 bigram,实现上最大的不同是什么?
 - bigram 基线在莎士比亚数据上训练并生成。

会话 2:self-attention 的数学核心($\approx 90\text{min}$)★ 全视频最重要一段

课前问题:

1. "让每个位置聚合它之前所有位置的信息",用矩阵乘法怎么一次做完?下三角矩阵在其中扮演什么角色?
2. 从"平均池化"升级到"加权聚合",权重应该由什么决定?Q 和 K 的点积为什么是合理的相关性度量?
3. mask 用 -inf 而不是 0 填充,过 softmax 后差别是什么?
4. 为什么要除以 $\sqrt{d_k}$?不除会在 softmax 上引发什么?(和你Chapter 0 读 Attention 论文时的答案对照)
 - 单头 attention 从零写出并通过;能向 Claude 讲清"数学技巧→attention"的推导链。

会话 3:多头 + FFN + Block 堆叠($\approx 75\text{min}$)

课前问题:

1. 多头相对单头,多出的表达能力来自哪?头之间共享什么、独立什么?
2. attention 负责"通信",FFN 负责"计算"——这个分工怎么理解?
3. 残差连接从梯度流的角度解决什么问题?(联想 #4 里手推过的深层梯度)
4. LayerNorm 和你写过的 BatchNorm,归一化的轴有何不同?为什么序列模型偏爱前者?
 - 完整 Transformer block 堆叠训练通过。

会话 4:放大与收尾($\approx 60\text{min}$)

课前问题:

1. dropout 加在哪几个位置?训练和推理时行为差别?
2. 把模型放大(层数/宽度/上下文)时,哪些超参必须联动调整?

3. 这份代码和 nanoGPT 的差距还剩什么?(为 Phase 2 留个钩子)

- 放大版训练完成,生成质量肉眼可见提升;→ 进入Chapter 7 的 exercises 与闭卷重构。
-

使用备注

- 会话间隔 1-3 天最佳;同一视频不建议一天连吃三个会话(违背间隔效应)。
- 课前问题答不上是**正常且正确**的状态——它们的作用是标记"待填的坑";收工自测时仍答不上,才说明该回看。
- 冲刺周加速的方式是"多排会话",不是"跳过收工状态检查"。